

Machine Learning und Künstliche Intelligenz

Vertiefung · BKWI2

Daten untersuchen · Modelle entwickeln · sicher prüfen
BPE 7 · Vertiefung · Version R8 · A4 · Schuljahr 2026/2027
Lizenz: CC BY-NC-SA 4.0 · Quellen, Lizenzen und KI-Hinweise

So arbeitest du mit diesem Lernskript

Wähle die passende Arbeitsvorlage und dokumentiere deinen Lernfortschritt direkt in Word.

1. A4 Desktop: Rechner oder Notebook. A5 Mobil: Smartphone oder kleines Tablet.
2. Speichere die Word-Datei als persönliche Lösungsfassung.
3. BKWI1 (BPE 6): Bearbeite die Kernaufgaben im Aufgabenblatt und nutze danach das Informationsblatt. BKWI2 (BPE 7): Folge dem Pflichtweg der drei Unterrichtswochen in Teil B; nutze die Informationsblätter und bearbeite die angegebenen Aufgabenblätter. Die Vertiefungsblätter enthalten zusätzliche Übungen. Grundlagen aus BKWI1 dienen als Vorwissen.
4. Markiere Aufgaben erst nach vollständiger Bearbeitung und nutze am Ende den Kompetenzcheck. Die Aufgaben sind ohne KI-Hilfe lösbar.
5. Für den Online-Arbeitsplatz öffne die öffentliche ML-Repository-Vorlage, wähle „Use this template“ und arbeite in deiner eigenen Kopie. Für die Offline-Arbeit liegen Python-Dateien und Datensätze im Materialpaket.

Die Kennung ML-Kxx-Axx bezeichnet eine feste Materialdatei im Repository; sie kann von der neuen Kapitelnummer abweichen. Nutze bei Abgaben und Dateinamen immer die angegebene Kennung.

Hinweis zur Erstellung

Dieses Unterrichtsmaterial wurde mit Unterstützung Künstlicher Intelligenz erstellt und fachlich strukturiert. Trotz sorgfältiger Prüfung können Fehler oder Unvollständigkeiten enthalten sein. Hinweise bitte an die Autorin Christine Janischek melden.

Inhaltsverzeichnis

Die Einträge führen direkt zu den Aufgaben-, Informations- und Vertiefungsblättern.

Teil B · BKWI2 · BPE 7 · Vertiefung

<u>Kapitel 13: Daten mit pandas untersuchen und visualisieren</u>	7
<u>13.1 Aufgabenblatt – Daten mit pandas untersuchen und visualisieren</u>	7
<u>13.2 Informationsblatt – Daten mit pandas untersuchen und visualisieren</u>	10
<u>13.3 Vertiefungsblatt – Daten mit pandas untersuchen und visualisieren</u>	15
<u>Kapitel 14: Große Datenmengen sichtbar machen</u>	16
<u>14.1 Aufgabenblatt – Große Datenmengen sichtbar machen</u>	16
<u>14.2 Informationsblatt – Große Datenmengen sichtbar machen</u>	17
<u>14.3 Vertiefungsblatt – Große Datenmengen sichtbar machen</u>	18
<u>Kapitel 15: Aggregieren, ohne Wichtiges zu verstecken</u>	19
<u>15.1 Aufgabenblatt – Aggregieren, ohne Wichtiges zu verstecken</u>	19
<u>15.2 Informationsblatt – Aggregieren, ohne Wichtiges zu verstecken</u>	20
<u>15.3 Vertiefungsblatt – Aggregieren, ohne Wichtiges zu verstecken</u>	22
<u>Kapitel 16: View zuerst: Dashboard des Lernagenten</u>	23
<u>16.1 Aufgabenblatt – View zuerst: Dashboard des Lernagenten</u>	23
<u>16.2 Informationsblatt – View zuerst: Dashboard des Lernagenten</u>	24
<u>16.3 Vertiefungsblatt – View zuerst: Dashboard des Lernagenten</u>	26
<u>Kapitel 17: Ein reproduzierbarer ML-Workflow mit Bibliotheken</u>	27
<u>17.1 Aufgabenblatt – Ein reproduzierbarer ML-Workflow mit Bibliotheken</u>	27
<u>17.2 Informationsblatt – Ein reproduzierbarer ML-Workflow mit Bibliotheken</u>	28
<u>17.3 Vertiefungsblatt – Ein reproduzierbarer ML-Workflow mit Bibliotheken</u>	29
<u>Kapitel 18: Code lesen: von Daten zu einer Klassifikation</u>	30
<u>18.1 Aufgabenblatt – Code lesen: von Daten zu einer Klassifikation</u>	30
<u>18.2 Informationsblatt – Code lesen: von Daten zu einer Klassifikation</u>	31
<u>18.3 Vertiefungsblatt – Code lesen: von Daten zu einer Klassifikation</u>	34
<u>Kapitel 19: Fehlerwerkstatt</u>	35
<u>19.1 Aufgabenblatt – Fehlerwerkstatt</u>	35
<u>19.2 Informationsblatt – Fehlerwerkstatt</u>	36
<u>19.3 Vertiefungsblatt – Fehlerwerkstatt</u>	37
<u>Kapitel 20: KI-Werkzeuge für BWL-Probleme auswählen</u>	38
<u>20.1 Aufgabenblatt – KI-Werkzeuge für BWL-Probleme auswählen</u>	38
<u>20.2 Informationsblatt – KI-Werkzeuge für BWL-Probleme auswählen</u>	39
<u>20.3 Vertiefungsblatt – KI-Werkzeuge für BWL-Probleme auswählen</u>	40
<u>Kapitel 21: Kriterien gewichten und bewerten</u>	41
<u>21.1 Aufgabenblatt – Kriterien gewichten und bewerten</u>	41
<u>21.2 Informationsblatt – Kriterien gewichten und bewerten</u>	42
<u>21.3 Vertiefungsblatt – Kriterien gewichten und bewerten</u>	44
<u>Kapitel 22: Wirtschaftlichkeit und Verantwortung zusammendenken</u>	45
<u>22.1 Aufgabenblatt – Wirtschaftlichkeit und Verantwortung zusammendenken</u>	45
<u>22.2 Informationsblatt – Wirtschaftlichkeit und Verantwortung zusammendenken</u>	46
<u>22.3 Vertiefungsblatt – Wirtschaftlichkeit und Verantwortung zusammendenken</u>	48

Diese eigenständige R8-Fassung umfasst Kapitel 13–22: BPE 7 · Vertiefung. Die Kapitelnummern bleiben für Verweise zwischen den drei Modulen erhalten. Jede Kernaufgabe ist mit dem Informationsblatt und den beigelegten lokalen Materialien bearbeitbar. Die Vertiefungsaufgaben erweitern die Kernaufgaben; fehlende Voraussetzungen aus einem anderen Modul werden im jeweiligen Materialhinweis benannt.

Optionale Start-Prompts für deinen KI-Coach

Wenn dir ein KI-Werkzeug zur Verfügung steht, können diese Prompts beim Denken und Lernen helfen. Alle Aufgaben lassen sich auch ohne KI anhand von Informationsblättern, Glossar und Materialdateien bearbeiten. Beschreibe zuerst deinen eigenen Stand und fordere nur Hilfe zum nächsten Schritt an.

Lernsituation	Start-Prompt
Begriff verstehen	„Ich möchte [Begriff] verstehen. Frage zuerst nach meiner eigenen Erklärung und gib dann höchstens ein Parallelbeispiel aus einem anderen Fall. Bitte keine Antwort auf die Skriptaufgabe.“
Code verstehen	„Ich erkläre diesen Python-Code so: [eigene Erklärung]. Prüfe nur meinen ersten Denkfehler und stelle eine Frage zum nächsten Schritt; keine korrigierte Gesamtlösung: [Code].“
Fehler untersuchen	„Bei [Meldung] vermute ich [Hypothese]. Welche eine Prüfung sollte ich als Nächstes selbst ausführen? Gib weder fertigen Code noch die Gesamtlösung.“
Daten prüfen	„Ich vermute bei [Spalten/Beschreibung] dieses Datenproblem: [Vermutung]. Stelle eine Gegenfrage und nenne höchstens einen passenden Prüfschritt, ohne Ergebnisse auszurechnen.“
Modell auswählen	„Für [Ziel] und [Daten] halte ich [Verfahren] für passend, weil [Grund]. Stelle mir eine Frage, mit der ich diese Wahl selbst prüfe; entscheide nicht für mich.“
Ergebnis beurteilen	„Meine eigene Deutung lautet [Deutung]. Frage, welche Aussage belegt ist und wo mir ein Gegenbeispiel fehlt. Gib keine fertige Bewertung oder Abgabeformulierung.“
Transfer zum Lernagenten	„Zu [Mockup] habe ich selbst [Eingaben/Ausgaben] notiert. Frage nach genau einem noch fehlenden Bestandteil. Erstelle weder Architektur noch Testfälle für mich.“

Lernsituation	Start-Prompt
Prüfregel: Übernimm keine Antwort ungeprüft. Vergleiche sie mit Skript, Datensatz und eigenem Programm. Frage nach Begründungen und teste Vorschläge an kleinen Beispielen. Auch wenn der KI das gesamte Lernskript vorliegt: Sie gibt keine Musterlösung, fertigen Code, fertige Grafik, durchgerechnete Aufgabenwerte oder abgabefertige Formulierung aus. Beschreibe deinen eigenen Ansatz und fordere jeweils nur einen Denimpuls an.	

Arbeitsregeln

1. Arbeite zuerst mit der Aufgabenstellung und deinen eigenen Überlegungen.
2. Öffne die Hilfen in der Reihenfolge Denimpuls → Strategiehilfe → Syntaxhilfe.
3. Führe Code nicht nur aus: Erkläre mindestens die Zeile, die du verändert hast.
4. Notiere Fehler und Korrekturen. Ein behobener Fehler ist ein sichtbarer Lernschritt.
5. Vergleiche erst nach einem eigenen Versuch mit einer Musterlösung.

Teil B · BPE 7: KI-Systeme in betrieblichen Situationen

BKWI2 · Vertiefung (BPE 7): [zur ML-Repository-Vorlage](#). Die Kerninhalte aus BKWI1 dienen als Vorwissen; bearbeite die Aufgaben in deiner eigenen Kopie. Ohne Online-Zugang sind Python-Starter und synthetische Daten im Schülerpaket enthalten.

Jetzt wechselt die Perspektive: Aus einzelnen Verfahren wird ein nachvollziehbarer Arbeitsprozess. Daten werden verdichtet, Bibliotheken gezielt eingesetzt und Werkzeuge anhand betrieblicher Anforderungen ausgewählt. Der Lernagent bleibt das Transferprojekt.

BWL-Perspektive

Ein technisch mögliches System ist nicht automatisch wirtschaftlich oder organisatorisch sinnvoll. Nutzen, Kosten, Risiken, Integration und Verantwortlichkeit gehören gemeinsam in die Entscheidung.

☐ Aufgabe vollständig erledigt

[Zum Aufgabenblatt](#) · [Zum Informationsblatt](#) · [Zum Inhaltsverzeichnis](#)

13. Daten mit pandas untersuchen und visualisieren

🎯 13.1 Aufgabenblatt – Daten mit pandas untersuchen und visualisieren

Material und Abgabe – Kern: `notebooks/daten/lerndaten\_lernagent.csv`, `notebooks/02\_daten\_erkunden.ipynb` oder `programme/02\_daten\_erkunden.py`. Lokale Kopie im Offlinepaket; GitHub optional. Ergebnisse: Datensteckbrief, Grafik und Fehlerprotokoll im Ordner `abgaben/ML-K13-A01/`. Etappen: Aufträge 1–3 und 4–5 in je einer Doppelstunde.

Ausgangssituation

Eure Lerngruppe soll vor einem Modell aus einer CSV-Datei eine belegbare Beobachtung gewinnen. Das Datenblatt im Projekt ist euer Ausgangspunkt.

Aufgabe – Jetzt tun

Öffne die CSV-Kopfzeile, arbeite dann mit der Notebook- oder VS-Code-Vorlage und gib Datensteckbrief, Grafik und Fehlerprotokoll ab.

Starte offline mit der Kopfzeile von `notebooks/daten/lerndaten\_lernagent.csv`. Öffne dann `notebooks/02\_daten\_erkunden.ipynb` oder in VS Code `programme/02\_daten\_erkunden.py` und erledige die fünf Aufträge nacheinander. Abgabe: Datensteckbrief, beschriftete Grafik mit Aussagegrenze und Fehlerprotokoll. Zeitplan: Aufträge 1–3 in der ersten, Aufträge 4–5 in der zweiten Doppelstunde; sichere nach jeder Etappe dein Zwischenergebnis.

ML-K13-A01 · Arbeitsauftrag 1: Datensteckbrief erstellen

1. Notiere Datenquelle und fachliche Bedeutung einer Zeile.
2. Bestimme Anzahl der Zeilen und Spalten.
3. Ordne jeder Spalte eine fachliche Bedeutung und einen erwarteten Datentyp zu.
4. Prüfe fehlende Werte und auffällige Minima oder Maxima.
5. Berechne für eine sinnvolle Zahlenspalte Minimum, Maximum, Mittelwert und Median.
6. Formuliere zwei offene Fragen, die der Datensatz nicht beantworten kann.

Merkmal	Ergebnis / Beobachtung
Datenquelle	
Eine Zeile beschreibt	
Anzahl Zeilen / Spalten	
fehlende Werte	
auffällige Werte	
Grenzen des Datensatzes	

Denkimpuls

Welche Kennzahl würde sich besonders verändern, wenn ein extrem großer Wert ergänzt wird?

Strategiehilfe

Vergleiche Mittelwert und Median und suche danach gezielt nach kleinen oder großen Ausreißern.

Syntaxhilfe

``daten['spalte'].min()`, `.max()`, `.mean()` und `.median()`.`

Arbeitsauftrag 2: Visualisierung mit Aussage

1. Formuliere eine Frage zur Verteilung einer Zahlenspalte.
2. Wähle das Diagramm und begründe die Wahl.
3. Erstelle die Grafik mit Titel, Achsenbeschriftungen und Einheit.
4. Notiere eine direkt sichtbare Beobachtung.
5. Ergänze eine mögliche Interpretation.
6. Formuliere eine Aussage, die aus der Grafik ausdrücklich nicht abgeleitet werden darf.

Baustein	Dein Text
Fragestellung	
Begründete Diagrammwahl	
Beobachtung	
vorsichtige Interpretation	
nicht zulässige Schlussfolgerung	

Arbeitsauftrag 3: Aussagen sortieren

1. Ordne diese Aussage als Beobachtung oder behauptete Ursache ein und begründe deine Wahl: „Bei den sichtbaren Datenpunkten treten hohe Bearbeitungszeiten häufiger zusammen mit niedrigeren Punktzahlen auf.“
2. Ordne auch diese Aussage ein und begründe, ob die vorhandenen Daten dafür genügen: „Langes Arbeiten verursacht schlechte Leistungen.“
3. Formuliere zwei alternative Erklärungen.
4. Nenne zusätzliche Daten, die zur Prüfung hilfreich wären.

Arbeitsauftrag 4: Import durchführen

1. Öffne `haeuser.csv` zunächst als Text und notiere Spaltennamen und Trennzeichen.
2. Führe den Import aus.
3. Lasse die ersten fünf und anschließend die letzten drei Zeilen anzeigen.
4. Vergleiche die Zahl der sichtbaren Zeilen mit der tatsächlichen Dateigröße.
5. Verändere den Pfad absichtlich. Lies die Fehlermeldung und stelle den korrekten Zustand wieder her.

Fehler sind Daten

Dokumentiere bei einem Fehler: Fehlermeldung, vermutete Ursache, durchgeführte Prüfung und Lösung. Diese Viererstruktur ist später auch für Modellfehler hilfreich.

Mein Fehlerprotokoll

Fehlermeldung / Beobachtung	vermutete Ursache	Prüfung	Lösung

Arbeitsauftrag 5: Datenqualität provozieren

1. Erstelle eine Kopie einer kleinen CSV-Datei.
2. Entferne einen Wert, vertausche ein Trennzeichen und schreibe ein Wort in eine Zahlenspalte.
3. Importiere die veränderte Datei.
4. Beschreibe für jeden Fehler, ob der Import scheitert oder erst die spätere Auswertung problematisch wird.
5. Stelle die Originaldatei wieder her.

Fachhilfe im Anhang: CSV · pandas · DataFrame

[Zum Informationsblatt](#) · [Zum Inhaltsverzeichnis](#)

13.2 Informationsblatt – Daten mit pandas untersuchen und visualisieren

Begriff und Ergebnisform – Ein Datensteckbrief ist eine knappe, prüfbare Beschreibung eines Datensatzes: Quelle, Bedeutung einer Zeile, Spalten samt Einheiten, Umfang, fehlende oder auffällige Werte und die Grenze der Aussage. Gib ihn als beschriftete Tabelle ab. Deine zusätzliche Grafik zeigt eine genau benannte Frage, Achsen und Einheit; das Fehlerprotokoll notiert Änderung, Beobachtung und Folge getrennt.

Kapitelroute

BKWI2 · Woche 1–2 · ca. 2 Unterrichtsstunden · BPE 7.1 · Vorbereitung von Datenanalyse und Programmbibliotheken

Das kannst du danach

1. Aufbau und Inhalt eines DataFrames systematisch beschreiben,
2. Spalten auswählen und einfache Kennzahlen berechnen,
3. fehlende und auffällige Werte erkennen,
4. eine Visualisierung aus einer fachlichen Frage ableiten,
5. Beobachtung, Interpretation und Ursache unterscheiden.

Startfrage

Ein Datensatz besitzt 500 Zeilen und keine leeren Felder. Welche weiteren Prüfungen sind nötig, bevor daraus ein Modell trainiert wird?

CSV mit pandas einlesen

pandas ist eine Python-Bibliothek für tabellarische Daten. Mit dem üblichen Kurznamen `pd` kann eine CSV-Datei in einen DataFrame geladen werden. Ein DataFrame ähnelt einer Tabelle, besitzt aber zusätzliche Funktionen zum Prüfen, Filtern, Berechnen und Visualisieren.

```
import pandas as pd

daten = pd.read_csv('notebooks/daten/haeuser.csv')
print(daten.head())
```

Durchgerechnetes Parallelbeispiel: Ausleihtage in der Schulbibliothek

Der gesamte kleine Übungsdatensatz lautet: Buch A 3 Tage, Buch B 5 Tage, Buch C 4 Tage. Als Tabelle hat er drei Zeilen und zwei Spalten (Buch, Ausleihtage). Die mittlere Ausleihdauer ist $(3 + 5 + 4) / 3 = 4$ Tage. Eine mögliche Frage für eine Grafik lautet: Wie unterscheiden sich die drei Ausleihdauern? Ein Balkendiagramm mit Buch auf der x-Achse und Tagen auf der y-Achse zeigt die Werte 3, 5, 4. Sichtbar ist nur, dass B hier am längsten ausgeliehen wurde; warum, zeigen diese Daten nicht.

So überträgst du die Methode: Frage formulieren → Spalten und Einheit prüfen → geeignete Kennzahl oder Grafik wählen → Beobachtung beschreiben → eine nicht belegbare Ursache ausdrücklich offenlassen. Verwende im Aufgabenblatt dafür die Lerndaten; die Bibliothekszahlen sind nur das Muster.

Hilfe 1 zu Auftrag 1: Was bedeutet genau eine Datenzeile, und welche Spalten liefern überhaupt Zahlen?

Hilfe 2 zu Auftrag 1: Lies im Bibliotheksbeispiel zunächst Zeilen, Spalten und Einheit ab. Übertrage diese Reihenfolge auf die lokale Lerndatei.

Hilfe 3 zu Auftrag 1: Beginne den Steckbrief mit Quelle, Zeilenbedeutung und Spaltenliste. Prüfe fehlende Werte, bevor du Kennzahlen interpretierst.

Hilfe 1 zu Auftrag 2: Welche eine fachliche Frage soll deine Grafik beantworten?

Hilfe 2 zu Auftrag 2: Vergleiche die Frage im Bibliotheksbeispiel mit den tatsächlich vorhandenen Zahlenspalten der Lerndatei.

Hilfe 3 zu Auftrag 2: Notiere Frage, geeignete Spalte, Einheit und passende Grafikform getrennt; füge erst dann Titel und Achsen hinzu.

Hilfe 1 zu Auftrag 3: Was siehst du in den Daten, und was vermutest du nur als Ursache?

Hilfe 2 zu Auftrag 3: Nutze die Unterscheidung zwischen Beobachtung und unbelegter Ursache im Bibliotheksbeispiel.

Hilfe 3 zu Auftrag 3: Formuliere zuerst einen Satz zu den sichtbaren Werten und danach einen zweiten Satz mit einer offenen Prüfungsfrage.

Hilfe 1 zu Auftrag 4: Woran erkennst du beim Blick in die CSV das Trennzeichen und die Spaltenüberschriften?

Hilfe 2 zu Auftrag 4: Gehe im Informationsblatt zur Importstelle und prüfe Pfad, erste Zeilen und Anzahl der geladenen Zeilen.

Hilfe 3 zu Auftrag 4: Ändere nur eine Pfadkomponente, lies die Fehlermeldung und stelle danach den ursprünglichen Pfad wieder her.

Hilfe 1 zu Auftrag 5: Was ändert sich, wenn ein Wert fehlt oder statt einer Zahl Text erscheint?

Hilfe 2 zu Auftrag 5: Vergleiche jeweils die Originaldatei und genau eine veränderte Kopie; prüfe zuerst den Import und danach die Auswertung.

Hilfe 3 zu Auftrag 5: Lege ein Protokoll mit Änderung, Importbefund und möglicher Folge für die Kennzahl an. Die Folge prüfst du selbst am veränderten Datensatz.

Code in vier Fragen lesen

Codebestandteil	Leitfrage
<code>import pandas as pd</code>	Welche Bibliothek wird unter welchem Kurznamen eingebunden?
<code>pd.read_csv(...)</code>	Welche Funktion liest die Datei ein?
<code>daten = ...</code>	Unter welchem Namen wird der DataFrame gespeichert?
<code>daten.head()</code>	Welche Stichprobe wird ausgegeben?

1. Daten mit pandas einlesen und den Import kontrollieren.

Der Datensteckbrief

Bevor gerechnet wird, entsteht ein kurzer Datensteckbrief. Er beantwortet: Woher kommen die Daten? Was beschreibt eine Zeile? Welche Spalten gibt es? Welche Einheiten und Wertebereiche gelten? Welche Zielsetzung verfolgt die spätere Auswertung?

Befehl	liefert	Prüffrage
<code>daten.head()</code>	erste Zeilen	Sehen Spalten und Beispiele plausibel aus?
<code>daten.shape</code>	Zeilen und Spalten	Ist die erwartete Größe vorhanden?
<code>daten.columns</code>	Spaltennamen	Sind Namen vollständig und eindeutig?
<code>daten.info()</code>	Datentypen und Belegung	Gibt es fehlende Werte oder falsche Typen?
<code>daten.describe()</code>	statistische Kennzahlen	Sind Wertebereiche und Verteilungen plausibel?

```
print(daten.head())
print(daten.shape)
print(daten.columns)
daten.info()
print(daten.describe())
```

Merksatz

Ein DataFrame ist technisch lesbar, wenn pandas ihn laden kann. Er ist fachlich brauchbar, wenn Bedeutung, Qualität und Grenzen der Daten verstanden und dokumentiert sind.

Spalten auswählen und Kennzahlen berechnen

```
punkte = daten['punkte']
print(punkte.min())
print(punkte.max())
print(punkte.mean())
print(punkte.median())
```

Mittelwert und Median beantworten ähnliche, aber nicht identische Fragen. Der Mittelwert reagiert stärker auf extreme Werte. Deshalb sollte eine Kennzahl nie ohne Kenntnis der Verteilung berichtet werden.

Erst die Frage, dann das Diagramm

Fragestellung	geeignete Darstellung	Beispiel
Wie sind Zahlenwerte verteilt?	Histogramm	Verteilung der Bearbeitungszeiten
Wie unterscheiden sich Kategorien?	Balkendiagramm	mittlere Punkte nach Thema
Hängen zwei Zahlenwerte zusammen?	Scatterplot	Bearbeitungszeit und Punkte
Wo liegen Ausreißer und Quartile?	Boxplot	Punkte je Themenbereich

Ein Diagramm ist keine Dekoration. Es ist eine visuelle Antwort auf eine vorher formulierte Frage. Titel, Achsen, Einheiten und gegebenenfalls Legende müssen die Aussage verständlich machen.

```
import matplotlib.pyplot as plt

daten['punkte'].plot(kind='hist', bins=6)
plt.title('Verteilung der erreichten Punkte')
plt.xlabel('Punkte von 0 bis 10')
plt.ylabel('Anzahl der Bearbeitungen')
plt.show()
```

Zusammenhang ist nicht Ursache

Ein Scatterplot kann zeigen, dass zwei Merkmale gemeinsam steigen oder fallen. Daraus folgt noch nicht, dass das eine Merkmal das andere verursacht. Bei Lerndaten können Vorwissen, Aufgabenschwierigkeit, Unterbrechungen oder Messfehler die sichtbare Beziehung beeinflussen.

Beispiel

Wenn längere Bearbeitungszeiten mit niedrigeren Punktzahlen auftreten, beweist das nicht, dass langes Arbeiten schlechte Ergebnisse verursacht. Schwierige Aufgaben könnten gleichzeitig mehr Zeit benötigen und zu niedrigeren Punktzahlen führen.

Gruppen bilden und vergleichen

```
mittelwerte = daten.groupby('thema')['punkte'].mean()
print(mittelwerte)
mittelwerte.plot(kind='bar')
```

Mit ``groupby()`` werden Datensätze nach Kategorien zusammengefasst. Ein Gruppenmittelwert kann Unterschiede sichtbar machen, verdeckt aber weiterhin Streuung und Einzelfälle. Deshalb wird die Zahl zusammen mit Gruppengröße und möglichst einer Verteilungsdarstellung betrachtet.

Prüffrage

Wie viele Fälle enthält jede Gruppe? Ein Mittelwert aus zwei Fällen ist anders zu beurteilen als ein Mittelwert aus zweihundert Fällen.

Transfer: Daten für den Lernagenten untersuchen

Der Lernagent soll später eine nächste Übung vorschlagen. Noch wird kein Modell trainiert. Zuerst wird geprüft, welche Muster sichtbar sind und welche Unsicherheiten bestehen.

Transferauftrag

1. Lade den künstlichen Lerndatensatz aus Kapitel 2.
2. Erstelle einen vollständigen Datensteckbrief.
3. Untersuche die Verteilung der Punkte.
4. Erstelle einen Scatterplot aus Bearbeitungszeit und Punkten.
5. Vergleiche mittlere Punktzahlen nach Thema.
6. Formuliere drei Beobachtungen, zwei mögliche Erklärungen und mindestens zwei Grenzen.
7. Entscheide, welche zusätzliche Information für eine Lernempfehlung besonders hilfreich wäre.

Datenschutz-Checkpoint

Arbeite ausschließlich mit künstlich erzeugten oder ausdrücklich freigegebenen Daten. Klarnamen, private Angaben und reale individuelle Leistungsprofile gehören nicht in das öffentliche Offlineprojekt.

Ergebnis: Management-Summary in fünf Sätzen

1. Der Datensatz beschreibt ...

2. Besonders auffällig ist ...

3. Eine mögliche, aber noch nicht bewiesene Erklärung ist ...

4. Für eine Lernempfehlung fehlt oder begrenzt ist ...

5. Als nächsten Analyseschritt schlage ich vor ...

Checkpoint Kapitel 13

1. Ich beschreibe Daten, bevor ich ein Modell auswähle.
2. Ich kann zentrale pandas-Prüfbefehle erklären.
3. Ich wähle Diagramme aus Fragestellungen.
4. Ich trenne Beobachtung, Interpretation und Ursache.
5. Ich beachte Datenminimierung und Datenschutz.

Offline-Praxis

Bearbeite ``aufgaben/ML-K13-A01.md`` mit ``notebooks/02_daten_erkunden.ipynb``. Die Datei ``notebooks/daten/lerndaten_lernagent.csv`` im Offlinepaket wird denselben Prüfweg verwenden.

Orientierung: Vier Fragen – vier Verfahren

In den folgenden Kapiteln steht nicht der möglichst komplizierte Code im Mittelpunkt. Entscheidend ist, aus einer fachlichen Frage das passende Verfahren abzuleiten, die Datenrollen zu bestimmen und Ergebnisse vorsichtig zu beurteilen.

Gemeinsamer ML-Workflow

1. Problem und gewünschte Ausgabe klären.
2. Datenquelle und Bedeutung einer Zeile beschreiben.
3. Features und gegebenenfalls Label festlegen.
4. Daten prüfen und vorbereiten.
5. Trainings- und Testdaten trennen.
6. Modell trainieren.
7. Vorhersagen oder Cluster erzeugen.
8. Ergebnis fachlich und mit Kennzahlen prüfen.
9. Grenzen und nächste Verbesserung dokumentieren.

Noch keine Magie

``fit()`` bedeutet nicht, dass ein Programm menschlich versteht. Die Methode passt Modellparameter an Trainingsdaten an. Ob daraus eine sinnvolle Lösung entsteht, muss anschließend geprüft werden.

1. Ich kann eine CSV-Datei mit pandas einlesen.

[Zum Aufgabenblatt](#) · [Zum Vertiefungsblatt](#) · [Zum Inhaltsverzeichnis](#)



13.3 Vertiefungsblatt – Daten mit pandas untersuchen und visualisieren

V1. Stelle zu `notebooks/daten/lerndaten\_lernagent.csv` eine zweite, von der Kernaufgabe verschiedene Frage. Prüfe, ob dafür eine andere Spalte oder Gruppierung gebraucht wird. Ergebnis: Skizze mit Titel, Achsen/Einheit, einem Satz zur sichtbaren Aussage und einer nicht belegbaren Ursachenvermutung, die ausdrücklich als solche markiert ist.

Material und Abgabe – Vertiefung: dieselbe lokale CSV, keine neue Vorlage. Ergebnis: zweite Grafiskizze und zwei Deutungssätze unter `abgaben/ML-K13-V01/` oder in der Arbeitsvorlage.

gewünschtes Ergebnis	Datenlage	Verfahren	Beispiel Lernagent
eine Zahl	Label als Zahlenwert vorhanden	Regression	erwartete Punktzahl
eine vorgegebene Klasse	Klassenlabel vorhanden	Entscheidungsbaum oder k-NN	Grundlagen / Übung / Vertiefung
unbekannte Gruppen	kein Ziel-Label	k-Means	ähnliche Arbeitsmuster

Leitregel

Zuerst wird das gewünschte Ergebnis formuliert. Erst danach wird ein Verfahren gewählt. Ein Algorithmus ist kein Selbstzweck.

☐ Aufgabe vollständig erledigt

[Zum Aufgabenblatt](#) · [Zum Informationsblatt](#) · [Zum Inhaltsverzeichnis](#)

14. Große Datenmengen sichtbar machen



14.1 Aufgabenblatt – Große Datenmengen sichtbar machen

Eine Lerngruppe möchte aus vielen Übungseinträgen einen Überblick erstellen. Eine Grafik soll eine konkrete Frage beantworten, ohne aus einem auffälligen Wert sofort eine Ursache abzuleiten.

Aufgabe – Jetzt tun

Wähle aus den vorhandenen Lerndaten eine fachliche Frage, die eine Grafik beantworten soll.

Ausgangssituation: Eine Lerngruppe möchte aus vielen Übungseinträgen einen Überblick erstellen. Eine Grafik soll eine konkrete Frage beantworten, ohne aus einem auffälligen Wert sofort eine Ursache abzuleiten.

Einstieg: Öffne lokal `notebooks/daten/lerndaten\_lernagent.csv` und lies zuerst die Spaltenüberschriften. Wähle eine messbare Frage zu Bearbeitungszeit oder Lösungsquote.

Arbeitsauftrag: Entwirf zu dieser CSV eine Grafik für eine selbst gewählte, messbare Frage. Nenne den genauen Spaltennamen, die Bedeutung einer Zeile und die Einheit. Begründe die Diagrammform, zeichne Titel und beschriftete Achsen und formuliere zwei Prüffragen, die vor der Veröffentlichung zu klären sind. Ergebnis: ein Grafikentwurf mit Datenbezug, Auswahlbegründung und zwei Prüffragen; ein Diagrammprogramm ist nicht erforderlich.

Material und Abgabe – Kern: lokale Datei `notebooks/daten/lerndaten\_lernagent.csv`. Papierentwurf möglich; keine installierte Bibliothek erforderlich. Ergebnis: Grafikentwurf als `abgaben/ML-K14-A01/grafikentwurf.pdf` oder in der Arbeitsvorlage.

☐ Aufgabe vollständig erledigt

[Zum Informationsblatt](#) · [Zum Inhaltsverzeichnis](#)



14.2 Informationsblatt – Große Datenmengen sichtbar machen

Begriff und Ergebnisform – Ein Grafikentwurf hält vor der Programmierung fest, welche Frage welche Daten beantworten sollen. Gib Frage, Datenquelle, Diagrammtyp, Titel, beschriftete Achsen/Einheiten, eine zulässige Aussage und eine Aussagegrenze an.

Durchgearbeitetes Parallelbeispiel – Schulbibliothek: Aus 30 Rückgaben wurden die Ausleihtage gezählt. Gesucht ist die Verteilung der Dauer, nicht der Unterschied zwischen Personen. Ein Histogramm mit Klassen 0–2, 3–5 und 6–8 Tage, x-Achse ‚Ausleihtage‘ und y-Achse ‚Anzahl Rückgaben‘ beantwortet diese Frage. Einzelne lange Ausleihen erklären noch nicht den Grund der Verspätung. Wähle für die Lerndaten selbst eine geeignete Form.

Hilfe 1 – Welche Spalte enthält die Größe, die deine Frage wirklich betrifft?

Hilfe 2 – Nutze die Übersicht Frage → Darstellung in 14.2 und prüfe: Verteilung, Gruppenvergleich, Zusammenhang oder Zeitverlauf?

Hilfe 3 – Schreibe zunächst Frage, x-Achse, y-Achse und Einheit auf; erst dann skizziere Balken oder Punkte.

Selbstkontrolle: Kann eine andere Person allein aus Titel, Achsen und Datenquelle erkennen, was verglichen wird? Ist eine nicht belegte Ursache ausdrücklich ausgeklammert?

Bei vielen Zeilen hilft bloßes Durchscrollen nicht. Visualisierung reduziert Komplexität, darf sie aber nicht verfälschen. Gute Diagramme beantworten eine konkrete Frage und zeigen zugleich Unsicherheit oder Grenzen.

Vom Auftrag zur Grafik

Frage	Geeignete Darstellung	Beispiel Lernagent
Wie häufig kommen Werte vor?	Histogramm	Verteilung der Bearbeitungszeit
Wie unterscheiden sich Gruppen?	Boxplot / Balken	Ergebnisse nach Lernmodul
Hängen zwei Größen zusammen?	Streudiagramm	Zeit und Lösungsquote
Wie entwickelt sich etwas?	Liniendiagramm	Lernfortschritt über Wochen
Wie groß sind Anteile?	Balken; Kreis nur bei wenigen Teilen	Anteile der Empfehlungsklassen

[Zum Aufgabenblatt](#) · [Zum Vertiefungsblatt](#) · [Zum Inhaltsverzeichnis](#)



14.3 Vertiefungsblatt – Große Datenmengen sichtbar machen

V1. Entwirf zu derselben CSV eine zweite Darstellung mit einer anderen fachlichen Frage. Erkläre, weshalb dieselbe Grafikform dafür geeignet oder ungeeignet ist. Ergebnis: zweite beschriftete Skizze und ein Vergleich in drei Sätzen.

Material und Abgabe – Vertiefung: gleiche CSV; keine weitere Vorlage. Ergebnis: zweite Skizze und Vergleich unter `abgaben/ML-K14-V01/` oder in der Arbeitsvorlage.

☐ Aufgabe vollständig erledigt

[Zum Aufgabenblatt](#) · [Zum Informationsblatt](#) · [Zum Inhaltsverzeichnis](#)

15. Aggregieren, ohne Wichtiges zu verstecken

15.1 Aufgabenblatt – Aggregieren, ohne Wichtiges zu verstecken

Eine Auswertung zeigt einen einzigen Mittelwert für alle Übungsergebnisse. Die Klasse vermutet, dass dabei Unterschiede zwischen Modulen oder kleine Gruppen übersehen werden.

Aufgabe – Jetzt tun

Wähle für die im Informationsblatt genannten Fragen jeweils eine geeignete Grafik und begründe die Wahl.

Ausgangssituation: Eine Auswertung zeigt einen einzigen Mittelwert für alle Übungsergebnisse. Die Klasse vermutet, dass dabei Unterschiede zwischen Modulen oder kleine Gruppen übersehen werden.

Einstieg: Lies in 15.2 die vier Fragen des Kurzauftrags und prüfe, ob jeweils Verteilung, Zusammenhang, Gruppenvergleich oder Zeitverlauf gemeint ist.

Arbeitsauftrag: Ordne den vier Fragen im Kurzauftrag 15.2 je eine passende Diagrammform zu und begründe jede Wahl mit den benötigten Spalten. Wähle dann einen eigenen Entwurf und überarbeite ihn nach den vier Prüfungen Achsen, Auswahl, Verdichtung und Datenschutz. **Ergebnis:** vierzeilige Zuordnungstabelle und Vorher-/Nachher-Skizze mit zwei begründeten Änderungen. Rechne keine nicht vorgegebenen Gruppenwerte aus.

Material und Abgabe – Kern: Fragen, Vier-Prüfungen-Raster und Codebeispiel in 15.2. Papierarbeit ohne zusätzliche Datei möglich; optional `notebooks/daten/lernergebnisse.csv`. **Ergebnis:** Tabelle und zwei Skizzen in der Arbeitsvorlage oder `abgaben/ML-K15-A01/`.

☐ **Aufgabe vollständig erledigt**

[Zum Informationsblatt](#) · [Zum Inhaltsverzeichnis](#)



15.2 Informationsblatt – Aggregieren, ohne Wichtiges zu verstecken

Begriff und Ergebnisform – Eine Zuordnungstabelle stellt jeder Frage eine Darstellungsform und die dazu erforderlichen Spalten gegenüber. Die Überarbeitung zeigt an einer Vorher-/Nachher-Skizze, welche Beschriftung oder Verdichtung geändert wurde und warum.

Durchgearbeitetes Parallelbeispiel – Mensa: An einem Tag warten drei Gruppen 2, 3 und 10 Minuten. Gegeben: 2, 3, 10 Minuten; gesucht: typische Wartezeit und auffällige Streuung. Mittelwert = $(2+3+10)/3 = 5$ Minuten; sortiert steht der Median bei 3 Minuten. Schritt 1: Werte addieren und durch drei teilen. Schritt 2: sortieren und mittleren Wert lesen. Der Mittelwert allein verdeckt die lange Wartezeit der dritten Gruppe. Dieses Rechenbeispiel verwendet keine Lerndaten und löst nicht die vier Diagrammfragen.

Hilfe 1 – Welcher Vergleich steckt in jeder der vier Fragen?

Hilfe 2 – Nimm die Frage/Darstellung-Übersicht aus 14.2 und das Prüfraster aus 15.2 zur Hand.

Hilfe 3 – Setze die vier Fragen zuerst in vier Tabellenzeilen. Markiere bei einer ausgewählten Skizze Achse, Auswahl, Verdichtung und kleine Gruppen.

Selbstkontrolle: Enthält jede Zeile Frage, Diagramm und Datenbezug? Sind bei der Überarbeitung zwei konkrete Änderungen erkennbar und bleibt bei kleinen Gruppen die Privatsphäre gewahrt?

Viele Einzelwerte werden häufig gruppiert und zusammengefasst. Mittelwerte sind nützlich, können aber Ausreißer und ungleiche Verteilungen verdecken. Ergänze deshalb Anzahl, Median, Streuung oder ein Verteilungsdiagramm.

```
import pandas as pd
import matplotlib.pyplot as plt

df = pd.read_csv('daten/lernergebnisse.csv')
summary = df.groupby('modul').agg(
    anzahl=('punktzahl', 'size'),
    mittelwert=('punktzahl', 'mean'),
    median=('punktzahl', 'median')
)
print(summary)
```

Vier Prüfungen vor der Veröffentlichung

1. Achsen: Beginnt die Skala sinnvoll und sind Einheiten sichtbar?
2. Auswahl: Fehlen Gruppen oder Zeiträume?
3. Verdichtung: Verdeckt der Durchschnitt eine problematische Streuung?
4. Datenschutz: Lassen sich einzelne Personen indirekt erkennen?

Praxisregel

Zeige kleine Gruppen nicht gesondert, wenn dadurch Personen erkennbar werden könnten. Fasse zusammen oder unterdrücke die Darstellung.

Kurzauftrag

Wähle für jede Frage ein Diagramm und begründe deine Wahl: Verteilung der Punkte; Zusammenhang zwischen Versuchen und Punkten; durchschnittliche Punkte je Modul; Fortschritt einer Klasse über sechs Wochen.

Denkimpuls

Benenne zuerst Datentyp und Vergleichsrichtung: Verteilung, Zusammenhang, Gruppenvergleich oder Zeitverlauf.

[Zum Aufgabenblatt](#) · [Zum Vertiefungsblatt](#) · [Zum Inhaltsverzeichnis](#)



15.3 Vertiefungsblatt – Aggregieren, ohne Wichtiges zu verstecken

V1. Vergleiche an einem selbst gewählten kleinen Zahlenbeispiel mit einem Ausreißer Mittelwert und Median. Gib Gegeben → Gesucht → Formel → zwei Rechenschritte → Ergebnis an und begründe, welche Kennzahl für eine Veröffentlichung vorsichtiger ist.

Material und Abgabe – Vertiefung: eigene, ausdrücklich beschriftete Beispieldaten mit mindestens drei Werten. Ergebnis: Rechenweg und Begründung in der Arbeitsvorlage oder `abgaben/ML-K15-V01/`.

☐ Aufgabe vollständig erledigt

[Zum Aufgabenblatt](#) · [Zum Informationsblatt](#) · [Zum Inhaltsverzeichnis](#)

16. View zuerst: Dashboard des Lernagenten



16.1 Aufgabenblatt – View zuerst: Dashboard des Lernagenten

Die Lehrkräfte wollen die bestehende Lernagenten-Ansicht für ihre Entscheidungen nutzen. Ein Dashboard darf Lernschwerpunkte zeigen, aber keine automatische Benotung auslösen.

Einstieg: Betrachte die Dashboard-Grafik in 16.2 und markiere zwei sichtbare Aussagen, deren Datengrundlage du prüfen musst.

ML-K16-A01 · Praxisauftrag: Management- und Lernansicht

Arbeitsdateien zu ML-K16-A01: [Aufgabenblatt im öffentlichen Repository](#). Öffne zuerst deine eigene Template-Kopie und speichere Ergebnisse dort unter `abgaben/ML-K16-A01/`.

Fach- oder Syntaxhilfe

Repository: [aufgaben/ML-K16-A01.md](#); passende CSV-Dateien liegen unter [notebooks/daten/](#).

Ausgangssituation: Die Lehrkräfte wollen die bestehende Lernagenten-Ansicht für ihre Entscheidungen nutzen. Ein Dashboard darf Lernschwerpunkte zeigen, aber keine automatische Benotung auslösen.

Einstieg: Betrachte die Dashboard-Grafik in 16.2 und markiere zwei sichtbare Aussagen, deren Datengrundlage du prüfen musst.

Arbeitsauftrag: Entwirf zur vorhandenen Dashboard-Grafik zwei getrennte Ansichten: eine für Lernende, eine für verantwortliche Lehrkräfte. Notiere für jede Ansicht drei konkrete Fragen, zwei passende Diagramme, die benötigten Daten und genau eine mögliche Handlung. Kennzeichne Unsicherheit und einen Weg zur menschlichen Prüfung.

Ergebnis: zwei beschriftete View-Skizzen plus eine Anforderungstabelle mit Adressat, sichtbarer Aussage, Datenquelle und Grenze. Die vorhandene Grafik dient nur als Ausgangspunkt; übernimm ihre Werte nicht als eigene Berechnung.

Material und Abgabe – Kern: Dashboard-Mockup und Tabellenraster in 16.2; optional

`notebooks/08\_grosse\_daten\_visualisieren.ipynb` oder `programme/08\_grosse\_daten\_visualisieren.py` im Offlinepaket. Zeichnen ohne Code möglich. Ergebnis: `abgaben/ML-K16-A01/ansichten.pdf` oder Arbeitsvorlage.

[Zum Informationsblatt](#) · [Zum Inhaltsverzeichnis](#)

16.2 Informationsblatt – View zuerst: Dashboard des Lernagenten

Begriff und Ergebnisform – Eine View-Skizze zeigt, was eine Person tatsächlich auf dem Bildschirm sieht und tun kann. Eine Anforderungstabelle verbindet jedes sichtbare Element mit seinem Adressaten, den benötigten Daten und einer Prüfung. Gib beide Skizzen und die Tabelle als getrennte Teile ab.

Durchgearbeitetes Parallelbeispiel – Bibliotheksbestand: Lernende sehen, ob ein Buch verfügbar ist und wann eine Rückgabe erwartet wird; das Büchereiteam sieht Bestandszahlen je Kategorie. Die erste Ansicht benötigt Ausleihstatus und Rückgabetag, die zweite zählt Bücher nach Kategorie. Bei unklarer Rückgabe zeigt die Ansicht ‚bitte nachfragen‘ statt ein sicheres Datum. Übertrage nur die Trennung von Adressat, Daten und Handlung auf den Lernagenten.


Hilfe 1 – Wer trifft mit der jeweiligen Ansicht welche Entscheidung?

Hilfe 2 – Leite aus jedem sichtbaren Element im Dashboard genau eine notwendige Datenquelle ab.

Hilfe 3 – Zeichne für jede Zielgruppe zunächst drei Kästen: Frage, Anzeige, Handlung; ergänze anschließend Unsicherheit und Prüfung.

Selbstkontrolle: Sind Lernenden- und Lehrkraftansicht klar getrennt, hat jede Aussage eine Datenquelle und ist eine automatische Benotung ausgeschlossen?

Bevor du Code schreibst, entwirfst du die Ergebnis-View. Dadurch wird sichtbar, welche Information die Software liefern muss und welche Daten dafür wirklich benötigt werden.



Mockup: Dashboard für die Lehrkraft. Die Übersicht zeigt Lernschwerpunkte, bleibt aber ausdrücklich eine Entscheidungshilfe und keine automatische Benotung.

Vom Mockup zur Anforderung

Element der View	Benötigte Daten	Logik
Lernstand	gelöste Aufgaben, Gewichtung	Score berechnen
Empfehlung	Score je Kompetenz, Schwellenwerte	nächsten Bedarf auswählen
Sicherheit	Datenmenge, Modellwahrscheinlichkeit	niedrig/mittel/hoch zuordnen

Element der View	Benötigte Daten	Logik
Begründung	stärkste Beobachtung	verständlichen Satz erzeugen

Transparenz

Die View zeigt nicht nur eine Empfehlung, sondern auch ihre Grundlage und Sicherheit. Das erleichtert Prüfung und Widerspruch.

Analysiere einen größeren Datensatz und erstelle zwei Ansichten: eine Detailansicht für Lernende und eine verdichtete Übersicht für Verantwortliche. Formuliere je Ansicht drei Fragen, zwei Diagramme und eine Handlungsempfehlung.

Denkimpuls

Welche Entscheidung soll die jeweilige Person treffen?

Strategiehilfe

Arbeite in dieser Reihenfolge: Frage → Kennzahl → Gruppierung → Diagramm → Aussage → Grenze.

Ansicht	Adressat	Kernfrage	Diagramm	Handlung
Detail				
Übersicht				

Diagramm-Review zu zweit

1. Ist die Kernaussage in zehn Sekunden erkennbar?
2. Sind Titel, Einheit, Zeitraum und Quelle vorhanden?
3. Ist die gewählte Darstellung fachlich passend?
4. Kann die Grafik zu einer falschen Schlussfolgerung verleiten?
5. Welche Information fehlt für eine Entscheidung?

Lerncheck

Markiere: ✓ sicher · ~ teilweise · ? noch unklar

- ☐ Ich wähle Diagramme passend zur Frage.
- ☐ Ich prüfe Aggregationen und kleine Gruppen.
- ☐ Ich kann aus einer View Daten- und Logikanforderungen ableiten.

[Zum Aufgabenblatt](#) · [Zum Vertiefungsblatt](#) · [Zum Inhaltsverzeichnis](#)

16.3 Vertiefungsblatt – View zuerst: Dashboard des Lernagenten

V1. Entwerfe für eine dritte Rolle (z. B. Schulsozialarbeit) nur die zulässigen Informationen und eine Rückfragefunktion. Begründe zwei Daten, die diese Rolle ausdrücklich nicht benötigt. Ergebnis: reduzierte View-Skizze und Datensparsamkeitsnotiz.

Material und Abgabe – Vertiefung: dieselbe View-Vorlage in 16.2, keine neue Datei. Ergebnis: dritte Skizze und Notiz unter `abgaben/ML-K16-V01/` oder Arbeitsvorlage.

☐ **Aufgabe vollständig erledigt**

[Zum Aufgabenblatt](#) · [Zum Informationsblatt](#) · [Zum Inhaltsverzeichnis](#)

17. Ein reproduzierbarer ML-Workflow mit Bibliotheken

17.1 Aufgabenblatt – Ein reproduzierbarer ML-Workflow mit Bibliotheken

Eine neue Person im Projektteam soll die Auswertung der Übungsdaten wiederholen können. Eine Liste mit Bibliotheksnamen reicht dafür nicht: Für jede Station muss der Prüfschritt erkennbar sein.

Aufgabe – Jetzt tun

Ordne die im Informationsblatt genannten Stationen einer überprüfbaren ML-Pipeline.

Ausgangssituation: Eine neue Person im Projektteam soll die Auswertung der Übungsdaten wiederholen können. Eine Liste mit Bibliotheksnamen reicht dafür nicht: Für jede Station muss der Prüfschritt erkennbar sein.

Einstieg: Öffne lokal ``notebooks/daten/lernergebnisse.csv``, lies die Kopfzeile und nimm anschließend die Stationstabelle in 17.2 zur Hand.

Arbeitsauftrag: Zeichne für diese Datei eine nachvollziehbare Pipeline aus Einlesen, Prüfen/Bereinigen, Aufteilen, Baseline, Modell, Evaluation und Kommunikation. Notiere je Station Eingang, Ausgabe und eine Prüffrage; markiere, an welcher Stelle Testdaten zurückgehalten werden und welche Angaben eine andere Person für denselben Lauf braucht. **Ergebnis:** sieben Stationen in einer Ablaufübersicht und eine kurze Reproduzierbarkeitsnotiz. Kein Modelltraining nötig.

Material und Abgabe – Kern: ``notebooks/daten/lernergebnisse.csv`` und Stationstabelle in 17.2. Papierarbeit möglich; Notebook/Programm 07 sind optional. **Ergebnis:** Pipeline und Notiz in der Arbeitsvorlage oder ``abgaben/ML-K17-A01/``.

☐ **Aufgabe vollständig erledigt**

[Zum Informationsblatt](#) · [Zum Inhaltsverzeichnis](#)

17.2 Informationsblatt – Ein reproduzierbarer ML-Workflow mit Bibliotheken

Begriff und Ergebnisform – Eine Pipeline-Übersicht ist eine Folge von Verarbeitungsschritten mit Ein- und Ausgabe je Station. Die Reproduzierbarkeitsnotiz hält Datenstand, Merkmale, Aufteilung, Zufallsstart und Modellparameter fest, damit eine zweite Person den Ablauf wiederholen kann.

Durchgearbeitetes Parallelbeispiel – Fahrradverleih: Eine CSV mit Ausleihen je Tag wird eingelesen (Ausgabe: Tabelle). Fehlende Tage werden markiert, die letzten zwei Wochen als Test zurückgehalten, ein einfacher Vorwochenwert dient als Baseline, ein zweiter Ansatz wird nur auf früheren Wochen entwickelt. Beide werden auf denselben zurückgehaltenen Tagen verglichen; ein Bericht nennt die größte Fehlwoche. Diese Stationen illustrieren die Reihenfolge, ohne die Lerndaten-Pipeline auszuarbeiten.

Hilfe 1 – Welche Datei steht am Anfang und was muss eine andere Person am Ende erhalten?

Hilfe 2 – Lies in 17.2 die Spalten Station/Artefakt/Prüffrage von oben nach unten.

Hilfe 3 – Setze zuerst sieben Kästen mit Pfeilen. Ergänze bei jedem Kasten nur Eingang, Ausgabe und eine Prüfnotiz.

Selbstkontrolle: Bleiben Testdaten bis zur Evaluation zurückgehalten, werden Baseline und Modell auf denselben Fällen geprüft und ist der Lauf aus deiner Notiz wiederholbar?

Bibliotheken ersparen wiederkehrende Arbeit. Sie ersetzen aber nicht das fachliche Denken. Wer nur Methodenaufrufe kopiert, kann ein lauffähiges und trotzdem falsches Ergebnis erzeugen. Deshalb dokumentieren wir jeden Schritt.

Bibliothek	Rolle	Typischer Einsatz
pandas	Tabellendaten	einlesen, filtern, gruppieren
matplotlib / seaborn	Visualisierung	Verteilungen und Zusammenhänge
scikit-learn	Machine Learning	Aufteilung, Training, Kennzahlen, Pipeline
Jupyter	Arbeitsumgebung	Code, Erklärung und Ergebnis verbinden

Eine Pipeline mit überprüfbaren Stationen

Station	Artefakt	Prüffrage
Einlesen	DataFrame + Datensteckbrief	Spalten, Typen und Umfang korrekt?
Bereinigen	dokumentierte Regeln	Welche Werte wurden verändert?
Aufteilen	Train/Test-Split	Kein Datenleck?
Baseline	einfacher Vergleich	Schlägt das Modell die Baseline?
Trainieren	Modell + Parameter	Ist der Lauf reproduzierbar?
Evaluieren	Kennzahlen + Fehlerfälle	Passt die Kennzahl zum Zweck?
Kommunizieren	View + Modellkarte	Sind Grenzen verständlich?

[Zum Aufgabenblatt](#) · [Zum Vertiefungsblatt](#) · [Zum Inhaltsverzeichnis](#)

17.3 Vertiefungsblatt – Ein reproduzierbarer ML-Workflow mit Bibliotheken

V1. Ergänze zu deiner Pipeline einen absichtlich problematischen Schritt, bei dem eine Information aus den Testdaten vorzeitig benutzt würde. Markiere ihn als Datenleck und beschreibe eine Korrektur. Ergebnis: annotierte Pipeline mit Vorher-/Nachher-Pfeil.

Material und Abgabe – Vertiefung: dieselbe Pipeline, keine neue Datei. Ergebnis: markiertes Datenleck und Korrektur unter `abgaben/ML-K17-V01/` oder Arbeitsvorlage.

☐ **Aufgabe vollständig erledigt**

[Zum Aufgabenblatt](#) · [Zum Informationsblatt](#) · [Zum Inhaltsverzeichnis](#)

18. Code lesen: von Daten zu einer Klassifikation

18.1 Aufgabenblatt – Code lesen: von Daten zu einer Klassifikation

Ein Notebook für den Lernagenten liefert Kennzahlen. Bevor die Lerngruppe das Ergebnis übernimmt, erklärt sie die wesentlichen Codezeilen und prüft, ob die Spaltennamen wirklich in der CSV stehen.

Einstieg: Öffne lokal ``notebooks/daten/lernergebnisse.csv`` und vergleiche die Kopfzeile mit dem Codeausschnitt in 18.2. Starte das Programm erst nach dieser Prüfung.

ML-K18-A01 · Praxisauftrag: Bibliotheken gezielt einsetzen

Ausgangssituation: Ein Notebook für den Lernagenten liefert Kennzahlen. Bevor die Lerngruppe das Ergebnis übernimmt, erklärt sie die wesentlichen Codezeilen und prüft, ob die Spaltennamen wirklich in der CSV stehen.

Einstieg: Öffne lokal ``notebooks/daten/lernergebnisse.csv`` und vergleiche die Kopfzeile mit dem Codeausschnitt in 18.2. Starte das Programm erst nach dieser Prüfung.

Arbeitsauftrag: Lies den Codeausschnitt in 18.2. Kennzeichne Datenquelle, drei Eingabemerkmale, Zielspalte, Train/Test-Trennung, Baseline, Baum und die gemeinsame Auswertung. Erläutere die Funktion von ``random_state`` und ``stratify`` in eigenen Worten. Prüfe einen tatsächlich vorhandenen Spaltennamen gegen die CSV und dokumentiere eine mögliche Fehlermeldung samt Korrektur. Ergebnis: kommentierter Codeausschnitt, eine kleine Tabelle Schritt → Zweck → Prüfpunkt und ein Wiederholungsprotokoll. Für den ersten Durchgang reicht Lesen ohne Modelllauf.

Material und Abgabe – Kern: Code in 18.2, ``notebooks/daten/lernergebnisse.csv``, optional ``notebooks/07_modellpruefung.ipynb`` oder ``programme/07_modellpruefung.py``. Ergebnis: kommentierter Code und Protokoll unter ``abgaben/ML-K18-A01/`` oder in der Arbeitsvorlage; kein Copilot nötig.

[Zum Informationsblatt](#) · [Zum Inhaltsverzeichnis](#)

18.2 Informationsblatt – Code lesen: von Daten zu einer Klassifikation

Begriff und Ergebnisform – Ein kommentierter Codeausschnitt erklärt die fachliche Absicht der relevanten Zeilen. Das Wiederholungsprotokoll nennt Datenquelle, Bibliotheksversionen, Zufallsstart, Merkmale, Zielgröße, Parameter und eine Beobachtung aus einem späteren Lauf; ein noch nicht ausgeführter Lauf wird nicht als Ergebnis ausgegeben.

Durchgearbeitetes Parallelbeispiel – Bibliotheksrückgaben: ``daten = pd.read_csv('rueckgaben.csv')`` lädt eine Tabelle; ``X = daten[['leihdauer_tage']]`` bezeichnet eine Eingabe und ``y = daten['rechtzeitig']`` das bekannte Ziel. Vor dem Lauf sind Kopfzeilen, fehlende Werte und die Trennung späterer Testfälle zu prüfen. Dieses kleine Beispiel erklärt Rollen im Code; es enthält weder die Lerndaten noch eine Modellgüte.

Hilfe 1 – Welche Namen stehen in der CSV-Kopfzeile wirklich?

Hilfe 2 – Vergleiche jede Zeile mit der Pipeline aus 17.2; trenne Eingaben X und Ziel y.

Hilfe 3 – Beginne dein Protokoll mit Pfad, Spalten, Split und Zufallsstart; trage Kennzahlen erst nach einem tatsächlichen Lauf ein.

Selbstkontrolle: Stimmen die drei Merkmalsnamen mit der CSV überein, bleiben Testfälle getrennt und sind nur tatsächlich beobachtete Kennzahlen als Ergebnis bezeichnet?

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.dummy import DummyClassifier
from sklearn.tree import DecisionTreeClassifier
from sklearn.metrics import classification_report

df = pd.read_csv('daten/lernergebnisse.csv')
X = df[['loesungsquote', 'versuche', 'bearbeitungszeit_min']]
y = df['empfehlung']
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)

baseline = DummyClassifier(strategy='most_frequent')
modell = DecisionTreeClassifier(max_depth=3, random_state=42)
for kandidat in [baseline, modell]:
    kandidat.fit(X_train, y_train)
    print(classification_report(y_test, kandidat.predict(X_test)))
```

Erkläre statt kopiere

1. Warum werden nur drei Merkmale in X aufgenommen?
2. Warum gehört die Empfehlung in y?
3. Wozu dienen random_state und stratify?
4. Warum wird die Baseline mittrainiert?
5. Welche Folge hätte ein sehr tiefer Entscheidungsbaum?

Syntaxhilfe

X bezeichnet üblicherweise die Eingabemerkmale, y die Zielgröße. Diese Namen sind Konventionen, keine besonderen Python-Schlüsselwörter.

Reproduzierbarkeit

Notiere Datenstand, Bibliotheksversionen, Zufallsstartwert, Merkmale, Zielgröße, Parameter und Kennzahlen. Eine andere Person soll deinen Lauf nachvollziehen können.

Erstelle oder ergänze ein Notebook, das einen Datensatz einliest, untersucht, aufteilt, mit einer Baseline und einem zweiten Modell bearbeitet und bewertet. Jede Codezelle erhält davor eine kurze fachliche Absicht und danach eine Ergebnisdeutung.

Denkimpuls

Wenn du eine Zeile nicht erklären kannst, zerlege sie in kleinere Schritte.

Strategiehilfe

Lege zuerst sieben Markdown-Überschriften für die Pipeline an. Fülle dann schrittweise Code und Deutung ein.

Fach- oder Syntaxhilfe

Repository-Einstieg: notebooks/02_daten_erkunden.ipynb, notebooks/03_lineare_regression.ipynb und notebooks/04_ki_tools_bwl.ipynb.

Minimaler Notebook-Check

- ☐ Kernel neu starten und alle Zellen in Reihenfolge ausführen.
- ☐ Keine versteckten Variablen aus früheren Läufen verwenden.
- ☐ Relative Dateipfade nutzen.
- ☐ Fehlende Werte sichtbar prüfen.
- ☐ Baseline und Modell auf denselben Testdaten vergleichen.
- ☐ Diagramme beschriften und Aussagen formulieren.

Modellkarte

Feld	Eintrag
Zweck und Nutzergruppe	
Trainingsdaten und Zielgröße	
Merkmale	
Kennzahlen und Baseline	
bekannte Grenzen	
nicht vorgesehene Nutzung	

Feld	Eintrag
menschlische Kontrolle	

[Zum Aufgabenblatt](#) · [Zum Vertiefungsblatt](#) · [Zum Inhaltsverzeichnis](#)



18.3 Vertiefungsblatt – Code lesen: von Daten zu einer Klassifikation

V1. Ändere gedanklich nur ``max_depth`` von 3 auf einen größeren Wert. Formuliere eine prüfbare Hypothese zur Trainings- und Testgüte, aber keine ungeprüfte Behauptung. Ergebnis: Hypothese, Testplan und leere Ergebnistabelle für einen späteren Lauf.

Material und Abgabe – Vertiefung: gleicher Code und dieselbe CSV. Ergebnis: Hypothese, Testplan und leere Prüftabelle unter ``abgaben/ML-K18-V01/`` oder Arbeitsvorlage.

☐ **Aufgabe vollständig erledigt**

[Zum Aufgabenblatt](#) · [Zum Informationsblatt](#) · [Zum Inhaltsverzeichnis](#)

19. Fehlerwerkstatt



19.1 Aufgabenblatt – Fehlerwerkstatt

Ein Team meldet, das Modell sei ‚kaputt‘. In der vorbereiteten CSV fehlen Werte und einzelne Eingaben wirken unplausibel. Ein zweiter Befund kann trotz ausführbarem Code fachlich falsch sein.

Aufgabe – Jetzt tun

Wähle einen technischen und einen fachlichen Fehler im bestehenden ML-Workflow.

Ausgangssituation: Ein Team meldet, das Modell sei ‚kaputt‘. In der vorbereiteten CSV fehlen Werte und einzelne Eingaben wirken unplausibel. Ein zweiter Befund kann trotz ausführbarem Code fachlich falsch sein.

Einstieg: Öffne ``notebooks/daten/lerndaten_fehlerhaft.csv`` und vergleiche zunächst Kopfzeile und drei Datenzeilen mit der normalen Datei ``lerndaten_lernagent.csv``.

Arbeitsauftrag: Wähle aus der fehlerhaften Datei einen technischen Daten-/Importfehler und aus der Tabelle in 19.2 einen davon unterscheidbaren fachlichen Modellfehler. Dokumentiere für jeden Fall Beobachtung, Hypothese, genau einen ersten Test, tatsächliches oder noch ausstehendes Ergebnis und eine begründete Korrektur. Ergebnis: zwei getrennte Fehlereinträge mit Dateiname und Prüfschritt; kennzeichne ungeprüfte Vermutungen ausdrücklich.

Material und Abgabe – Kern: ``notebooks/daten/lerndaten_fehlerhaft.csv``, Vergleich ``lerndaten_lernagent.csv`` und Fehlertabelle in 19.2. Optional ``programme/02_daten_erkunden.py``. Ergebnis: zwei Fehlereinträge unter ``abgaben/ML-K19-A01/`` oder Arbeitsvorlage.

☐ Aufgabe vollständig erledigt

[Zum Informationsblatt](#) · [Zum Inhaltsverzeichnis](#)



19.2 Informationsblatt – Fehlerwerkstatt

Begriff und Ergebnisform – Ein Fehlereintrag ist ein kleines Prüfprotokoll mit fünf Feldern: Beobachtung, Hypothese, Test, Befund und Korrektur. Eine Hypothese ist zunächst eine Vermutung; erst der dokumentierte Test liefert einen Befund.

Durchgearbeitetes Parallelbeispiel – Bibliotheksdatei: Eine CSV enthält die Spalte `ausleihtag`, das Programm sucht `ausleih\_tage`. Beobachtung: `KeyError`; Hypothese: Spaltenname weicht ab; Test: Kopfzeile ausgeben; Befund: `ausleihtag` steht dort; Korrektur: den Code an die vorhandene Spalte anpassen. Die Lernagenten-Datei und ein fachlicher Modellfehler bleiben für die Aufgabe offen.

Hilfe 1 – Ist der erste Fehler bereits in Daten oder Dateipfad sichtbar, oder entsteht er erst bei der Deutung?

Hilfe 2 – Nutze in 19.2 die Symptom/Ursache/Prüfung-Tabelle und ändere pro Test nur eine Sache.

Hilfe 3 – Schreibe die fünf Felder als leere Vorlage für beide Fälle; trage einen Befund nur ein, wenn du ihn wirklich geprüft hast.

Selbstkontrolle: Unterscheiden sich die zwei Fehlertypen, ist jeweils ein konkreter Test genannt und bleibt eine nicht durchgeführte Prüfung als offen gekennzeichnet?

Analysiere nicht nur Fehlermeldungen des Programms, sondern auch fachliche Fehler.

Symptom	Mögliche Ursache	Prüfung
Datei nicht gefunden	Pfad oder Arbeitsordner falsch	aktuellen Ordner und relativen Pfad prüfen
Text statt Zahl	Datentyp oder Dezimalzeichen	dtypes und Beispielwerte ansehen
sehr hohe Testgüte	Datenleck oder Duplikate	Merkmale und Splitting untersuchen
stark schwankende Güte	kleiner Datensatz / Zufall	mehrere Splits oder Cross-Validation
gute Kennzahl, schlechte Praxis	falsches Ziel oder falsche Metrik	Stakeholder und Fehlerfolgen prüfen

Debug-Auftrag

Wähle einen technischen und einen fachlichen Fehler. Dokumentiere Beobachtung, Hypothese, Test, Ergebnis und Korrektur.

Denkimpuls

Ändere pro Test nur eine Sache. So erkennst du, welche Änderung wirkt.

Lerncheck

Markiere: ✓ sicher · ~ teilweise · ? noch unklar

- ☐ Ich kann die Rollen zentraler Bibliotheken erklären.
- ☐ Ich dokumentiere einen reproduzierbaren Workflow.
- ☐ Ich vergleiche ein Modell mit einer Baseline.
- ☐ Ich trenne technische und fachliche Fehler.



19.3 Vertiefungsblatt – Fehlerwerkstatt

V1. Untersuche zusätzlich einen negativen Zeitwert oder einen fehlenden Punktwert in der fehlerhaften Datei. Beschreibe eine fachliche Folge, die ein rein technischer Lauf übersehen könnte. Ergebnis: dritter Fehlereintrag mit Prüfgrenze.

Material und Abgabe – Vertiefung: dieselbe fehlerhafte CSV. Ergebnis: dritter Eintrag unter `abgaben/ML-K19-V01/` oder Arbeitsvorlage.

☐ **Aufgabe vollständig erledigt**

[Zum Aufgabenblatt](#) · [Zum Informationsblatt](#) · [Zum Inhaltsverzeichnis](#)

20. KI-Werkzeuge für BWL-Probleme auswählen

20.1 Aufgabenblatt – KI-Werkzeuge für BWL-Probleme auswählen

Die Schule überlegt, ob ein Lernagent eine nächste Übung empfehlen soll. Dafür stehen eine feste Regel, eine eigene ML-Lösung oder ein externer Dienst im Raum.

Aufgabe – Jetzt tun

Formuliere einen konkreten betrieblichen Bedarf für den Lernagenten.

Ausgangssituation: Die Schule überlegt, ob ein Lernagent eine nächste Übung empfehlen soll. Dafür stehen eine feste Regel, eine eigene ML-Lösung oder ein externer Dienst im Raum.

Einstieg: Lies in 20.2 den Problem-Canvas und notiere zuerst genau eine Entscheidung, die das System unterstützen soll.

Arbeitsauftrag: Formuliere für den Lernagenten einen überprüfbaren Bedarf mit Zielgruppe, Entscheidung, vorhandenen Daten und Fehlerfolgen. Vergleiche anschließend Build, Buy und No-AI nach Anpassbarkeit, laufendem Aufwand, Datenweitergabe und Erklärbarkeit. Lege mindestens ein Ausschlusskriterium fest, bevor du eine Variante vorschlägst. **Ergebnis:** ausgefüllter Problem-Canvas und eine dreizeilige Entscheidungsvorlage mit Annahmen und einem offenen Prüfpunkt; du musst kein Produkt kaufen oder programmieren.

Material und Abgabe – Kern: Problem-Canvas und Variantenbeschreibungen in 20.2. Keine Online-Recherche oder Lizenz nötig; Ergebnis in der Arbeitsvorlage oder `abgaben/ML-K20-A01/entscheidung.pdf`.

☐ **Aufgabe vollständig erledigt**

[Zum Informationsblatt](#) · [Zum Inhaltsverzeichnis](#)



20.2 Informationsblatt – KI-Werkzeuge für BWL-Probleme auswählen

Begriff und Ergebnisform – Ein Problem-Canvas beschreibt Nutzer, Entscheidung, gewünschtes Ergebnis, Daten, Fehlerfolgen und Verantwortung. Die Entscheidungsvorlage stellt Varianten nach denselben Kriterien gegenüber und nennt Annahmen und nächste Prüfung statt eine unbelegte Siegerbehauptung.

Durchgearbeitetes Parallelbeispiel – Mensa-Bestellungen: Die Küche möchte die Anzahl vegetarischer Menüs am Vortag besser einschätzen. Eine feste Vorbestellregel könnte reichen; ein eigener Prognosecode wäre anpassbar, aber zu pflegen; ein externer Dienst müsste Bestelldaten erhalten. Zuerst wird geprüft, ob tägliche Bestellzahlen überhaupt vorliegen und ob ein einfacher Ablauf das Problem schon löst. Dieses Beispiel entscheidet nichts über den Lernagenten.

Hilfe 1 – Welche einzelne Entscheidung soll im Schulalltag besser werden?

Hilfe 2 – Fülle zuerst Nutzer, Ergebnis, Daten und Fehlerfolge im Canvas aus; vergleiche dann alle drei Varianten an gleichen Kriterien.

Hilfe 3 – Schreibe ein Ausschlusskriterium über die Tabelle und markiere jeden nicht belegten Aufwand als Annahme.

Selbstkontrolle: Ist der Bedarf messbar, sind Build/Buy/No-AI gleichartig verglichen und wurde kein fehlender Kostennachweis als Tatsache ausgegeben?

Nicht das Werkzeug steht am Anfang, sondern der betriebliche Bedarf. „Wir wollen KI einsetzen“ ist noch keine Problemdefinition. Eine gute Auswahl macht Kriterien, Gewichtungen und Unsicherheit sichtbar.

Das Problem schärfen

Unklar	Prüfbar formuliert
Kundenservice verbessern	Antwortzeit für Standardanfragen senken, ohne Fehlerquote zu erhöhen
Lernen personalisieren	passende Folgeübung vorschlagen und Begründung anzeigen
Verkäufe steigern	Nachfrage pro Produktgruppe für vier Wochen prognostizieren
Dokumente automatisieren	Rechnungsdaten extrahieren und zur Prüfung markieren

Problem-Canvas

Nutzer · Entscheidung · gewünschtes Ergebnis · verfügbare Daten · Fehlerfolgen · Prozessintegration · Verantwortliche

Build, Buy oder No-AI?

1. Build: selbst entwickeln; hohe Anpassbarkeit, aber Entwicklungs- und Betriebsaufwand.
2. Buy: vorhandenes Produkt nutzen; schneller Start, aber Abhängigkeit und Integrationsfragen.
3. No-AI: Regeln, Suche oder Prozessverbesserung; oft transparenter und günstiger.

[Zum Aufgabenblatt](#) · [Zum Vertiefungsblatt](#) · [Zum Inhaltsverzeichnis](#)



20.3 Vertiefungsblatt – KI-Werkzeuge für BWL-Probleme auswählen

V1. Ändere eine Rahmenbedingung: Externe Datenweitergabe ist ausgeschlossen. Prüfe erneut, welche Varianten überhaupt verbleiben. Ergebnis: eine überarbeitete Entscheidungsvorlage mit Begründung der Änderung.

Material und Abgabe – Vertiefung: dieselbe Entscheidungsvorlage, neue Rahmenbedingung im Aufgabentext.
Ergebnis: zweite Fassung unter `abgaben/ML-K20-V01/` oder Arbeitsvorlage.

☐ **Aufgabe vollständig erledigt**

[Zum Aufgabenblatt](#) · [Zum Informationsblatt](#) · [Zum Inhaltsverzeichnis](#)

21. Kriterien gewichten und bewerten



21.1 Aufgabenblatt – Kriterien gewichten und bewerten

Ein Entscheidungsteam bewertet für den Lernagenten mehrere technische Wege. Es möchte die Gewichte und Punktwerte offenlegen, statt eine scheinbar objektive Rangfolge zu behaupten.

Einstieg: Lies in 21.2 die leere Kriterienmatrix und prüfe, ob die sechs Gewichte zusammen 100 ergeben. Trage noch keine Punktwerte ohne begründete Annahme ein.

ML-K21-A01 · Fallstudie: Werkzeug für einen Lernagenten

Fach- oder Syntaxhilfe

Repository: `aufgaben/ML-K21-A01.md` sowie `notebooks/04_ki_tools_bwl.ipynb`.

Ausgangssituation: Ein Entscheidungsteam bewertet für den Lernagenten mehrere technische Wege. Es möchte die Gewichte und Punktwerte offenlegen, statt eine scheinbar objektive Rangfolge zu behaupten.

Einstieg: Lies in 21.2 die leere Kriterienmatrix und prüfe, ob die sechs Gewichte zusammen 100 ergeben. Trage noch keine Punktwerte ohne begründete Annahme ein.

Arbeitsauftrag: Vergleiche für den Lernagenten die drei in 21.2 genannten Wege (Regeln, ML plus Textbausteine, ML plus externes Sprachmodell). Lege vor der Bewertung ein Muss-Kriterium fest; fülle dann die Kriterienmatrix mit begründeten Punktwerten 1 bis 5 aus und rechne die gewichteten Werte. Ändere danach ein Gewicht um 10 Prozentpunkte und gleiche andere Gewichte so aus, dass die Summe 100 bleibt. Ergebnis: ausgefüllte Matrix mit Rechenweg, Rangfolge vor/nach der Änderung und eine Entscheidungsvorlage, die Unsicherheit nennt. Falls ein Muss-Kriterium eine Variante ausschließt, kennzeichne sie statt sie mit Punkten zu retten.

Material und Abgabe – Kern: Kriterienmatrix in 21.2; optional ``notebooks/04_ki_tools_bwl.ipynb`` oder ``programme/04_ki_tools_bwl.py`` aus dem Offlinepaket. Papier- oder Tabellenrechnung genügt. Ergebnis: Matrix und Entscheidung unter ``abgaben/ML-K21-A01/`` oder Arbeitsvorlage.

[Zum Informationsblatt](#) · [Zum Inhaltsverzeichnis](#)



21.2 Informationsblatt – Kriterien gewichten und bewerten

Begriff und Ergebnisform – Eine Nutzwertanalyse vergleicht Varianten mit denselben Kriterien. Gib Gewicht, Punktwert, Produkt Gewicht $\times$ Punkte je Zeile, Summe geteilt durch 100 und begründete Rangfolge an. Eine Sensitivitätsanalyse wiederholt die Rechnung mit einer bewusst geänderten, wieder auf 100 normierten Gewichtung.

Durchgearbeitetes Parallelbeispiel – Parallelrechnung – Fahrradständer: Eine Schule vergleicht zwei Standorte nur nach Wegnähe (60 %) und Wetterdach (40 %). Standort A erhält 4 und 2 Punkte: $60 \times 4 + 40 \times 2 = 320$; durch 100 ergibt das 3,2. Standort B erhält 3 und 5 Punkte: $60 \times 3 + 40 \times 5 = 380$; durch 100 ergibt das 3,8. Gegeben sind Gewichte und Punkte, gesucht ist ein vergleichbarer Nutzwert. Schritt 1: je Kriterium Gewicht mit Punktzahl multiplizieren. Schritt 2: Produkte addieren und durch 100 teilen. Die Werte sind Annahmen; für den Lernagenten gelten andere Kriterien und es gibt hier keine fertige Wahl.

Hilfe 1 – Welches Muss-Kriterium könnte eine Variante schon vor der Punktevergabe ausschließen?

Hilfe 2 – Übernimm die Matrix aus 21.2 und rechne eine Zeile nach dem Fahrradständer-Beispiel.

Hilfe 3 – Notiere alte und neue Gewichte nebeneinander; prüfe beide Summen auf 100, bevor du Rangfolgen vergleichst.

Selbstkontrolle: Sind Punktwerte begründet, beide Gewichtssummen 100, alle Produkte nachvollziehbar und eine veränderte Rangfolge als empfindliche Entscheidung erkennbar?

Eine Nutzwertanalyse zwingt dazu, Prioritäten offenzulegen. Die Punktzahl ersetzt keine Entscheidung, strukturiert aber die Diskussion.

Kriterium	Gewicht	Tool A (1–5)	Tool B (1–5)	Eigenbau (1–5)
fachliche Eignung	25			
Datenschutz	20			
Erklärbarkeit	15			
Integration	15			
Kosten über 3 Jahre	15			
Anbieterabhängigkeit	10			
Summe	100			

gewichteter_nutzen = sum(gewicht * punkte for gewicht, punkte in bewertungen)

Bei Gewichten in Prozent anschließend durch 100 teilen.

Sensitivitätsanalyse

Ändere ein wichtiges Gewicht, etwa Datenschutz von 20 auf 30 Prozent, und gleiche andere Gewichte aus. Bleibt die Rangfolge stabil? Wenn eine kleine Änderung die Entscheidung dreht, ist das Ergebnis empfindlich und sollte nicht als eindeutig dargestellt werden.

Achtung Scheingenauigkeit

Punktwerte beruhen auf Annahmen. Belege, Unsicherheiten und Ausschlusskriterien gehören neben die Rechnung.

Eine Schule möchte Übungen empfehlen und kurze Lernhinweise erzeugen. Vergleiche drei Lösungswege: regelbasiert, klassisches ML plus Textbausteine, ML plus externes Sprachmodell. Erstelle Problem-Canvas, Muss-Kriterien, Nutzwertanalyse und Sensitivitätsprüfung.

Denkimpuls

Welche Daten müssten die drei Varianten an wen übertragen?

Strategiehilfe

Definiere zuerst Ausschlusskriterien. Nur verbleibende Varianten erhalten Punkte.

Variante	Stärke	Risiko	Offene Evidenz
Regeln			
ML + Textbausteine			
ML + Sprachmodell			

Entscheidungsvorlage auf einer Seite

1. Entscheidungssatz: Welche Variante wird wofür empfohlen?
2. Begründung: drei wichtigste Kriterien und Belege.
3. Risiken: wichtigste Fehlerfolge und Schutzmaßnahmen.
4. Wirtschaftlichkeit: Einmal- und laufende Aufwände.
5. Pilot: kleinster sinnvoller Test mit Abbruchkriterien.

[Zum Aufgabenblatt](#) · [Zum Vertiefungsblatt](#) · [Zum Inhaltsverzeichnis](#)



21.3 Vertiefungsblatt – Kriterien gewichten und bewerten

V1. Teste zusätzlich eine zweite begründete Gewichtsverschiebung zugunsten der Erklärbarkeit. Rechne die neue Rangfolge und benenne ein Kriterium, dessen Punktwert noch empirisch überprüft werden müsste. Ergebnis: dritte Gewichtsspalte und kurze Unsicherheitsnotiz.

Material und Abgabe – Vertiefung: gleiche Kriterienmatrix, keine neue Datei. Ergebnis: dritte Gewichtsspalte und Unsicherheitsnotiz unter `abgaben/ML-K21-V01/` oder Arbeitsvorlage.

☐ **Aufgabe vollständig erledigt**

[Zum Aufgabenblatt](#) · [Zum Informationsblatt](#) · [Zum Inhaltsverzeichnis](#)

22. Wirtschaftlichkeit und Verantwortung zusammendenken

22.1 Aufgabenblatt – Wirtschaftlichkeit und Verantwortung zusammendenken

Die Projektgruppe muss ihre Werkzeugentscheidung gegenüber einer Schulleitung erklären. Dafür reichen technische Fachwörter oder ein einzelner Punktwert nicht aus.

Aufgabe – Jetzt tun

Stelle die vorhandene Werkzeugentscheidung in einem 90-Sekunden-Pitch vor.

Ausgangssituation: Die Projektgruppe muss ihre Werkzeugentscheidung gegenüber einer Schulleitung erklären. Dafür reichen technische Fachwörter oder ein einzelner Punktwert nicht aus.

Einstieg: Nimm deine ausgefüllte Entscheidungsvorlage aus Kapitel 20/21 und markiere Problem, Beleg, Hauptrisiko und nächsten Pilotschritt.

Arbeitsauftrag: Bereite einen 90-Sekunden-Pitch zur eigenen Entscheidung für den Lernagenten vor. Stelle Problem, Zielgruppe, empfohlenen Weg, einen überprüfbaren Beleg, laufenden Aufwand, Hauptrisiko mit Schutzmaßnahme und einen begrenzten Pilotschritt dar. **Ergebnis:** Stichwortkarte mit höchstens sieben Zeilen und ein mündlicher Vortrag; kennzeichne fehlende Kosten als Schätzung, nicht als feststehende Zahl.

Material und Abgabe – Kern: eigene Entscheidung aus 20/21 und Dimensionen-Tabelle in 22.2. Keine zusätzliche Datei nötig. **Ergebnis:** Stichwortkarte unter `abgaben/ML-K22-A01/` oder in der Arbeitsvorlage plus mündlicher Vortrag.

☐ **Aufgabe vollständig erledigt**

[Zum Informationsblatt](#) · [Zum Inhaltsverzeichnis](#)



22.2 Informationsblatt – Wirtschaftlichkeit und Verantwortung

zusammendenken

Begriff und Ergebnisform – Ein Pitch ist eine kurze, adressatengerechte Begründung einer Entscheidung. Die Stichwortkarte hält Reihenfolge, Beleg, Risiko und nächsten Schritt fest; sie ist kein vollständiges Manuskript.

Durchgearbeitetes Parallelbeispiel – Schulbücherei: ‚Wir möchten Rückgaben besser planen. Ein einfacher Erinnerungsprozess reicht für einen kleinen Test. Dafür sprechen die vorhandenen Ausleihdaten; ungeprüfte Empfängeradressen sind das Hauptrisiko. Wir starten mit zehn synthetischen Fällen und stoppen bei einer falschen Zuordnung.‘ Diese Reihenfolge zeigt Problem, Weg, Beleg, Risiko und Pilot, ohne die Entscheidung zum Lernagenten zu liefern.

Hilfe 1 – Welche Entscheidung soll die Schulleitung nach deinem Vortrag verstehen?

Hilfe 2 – Nutze die Dimensionen in 22.2 und die Entscheidungsvorlage aus 21.2; beginne mit dem Entscheidungssatz.

Hilfe 3 – Schreibe je einen Stichpunkt zu Problem, Weg, Beleg, Risiko, Kostenannahme und Pilot. Lies laut und kürze auf 90 Sekunden.

Selbstkontrolle: Kann jemand ohne Modellwissen Empfehlung, Beleg, Verantwortung und Stoppsignal wiedergeben? Passt der Vortrag in 90 Sekunden?

Dimension	Fragen
Nutzen	Welche Zeit, Qualität oder Wirkung verbessert sich messbar?
Kosten	Lizenz, Entwicklung, Integration, Schulung, Kontrolle, Exit?
Risiko	Welche Schäden sind möglich und wer trägt sie?
Organisation	Wer pflegt Daten, Modell, Regeln und Dokumentation?
Recht & Datenschutz	Welche Grundlage, Zweckbindung und Schutzmaßnahmen gelten?
Akzeptanz	Können Betroffene Ergebnis und Widerspruchsweg verstehen?

Pitch in 90 Sekunden

Stelle deine Entscheidung einer Schulleitung oder Geschäftsführung vor. Nenne Problem, Empfehlung, wichtigsten Beleg, Hauptrisiko und nächsten Pilotschritt.

Denkimpuls

Beginne mit dem Entscheidungssatz – nicht mit der Technik.

Lerncheck

Markiere: ✓ sicher · ~ teilweise · ? noch unklar

- ☐ Ich beginne bei Problem und Entscheidung.
- ☐ Ich kann Kriterien gewichten und eine Sensitivität prüfen.

☐ Ich berücksichtige laufende Kosten, Datenschutz und Exit.

[Zum Aufgabenblatt](#) · [Zum Vertiefungsblatt](#) · [Zum Inhaltsverzeichnis](#)



22.3 Vertiefungsblatt – Wirtschaftlichkeit und Verantwortung zusammendenken

V1. Halte denselben Pitch für eine Lernendenvertretung. Ersetze Fachsprache durch Alltagssprache und füge den Widerspruchsweg hinzu. Ergebnis: zweite Stichwortkarte mit zwei begründeten Änderungen.

Material und Abgabe – Vertiefung: dieselben Unterlagen. Ergebnis: zweite Stichwortkarte unter `abgaben/ML-K22-V01/` oder Arbeitsvorlage.

☐ Aufgabe vollständig erledigt

[Zum Aufgabenblatt](#) · [Zum Informationsblatt](#) · [Zum Inhaltsverzeichnis](#)

Anhang: Fachglossar Machine Learning

Schlage den verlinkten Begriff zuerst hier nach und gehe dann über „Zum Inhaltsverzeichnis“ zu deinem Auftrag zurück. Die Beispiele erklären Begriffe, lösen aber keine Arbeitsaufgabe.

Merkmal: Eine messbare Eingabe des Modells, zum Beispiel die Anzahl der Versuche. Ein Merkmal allein ist noch keine Empfehlung.

Label: Die bekannte Zielangabe zu einem Übungsfall, zum Beispiel die nachträglich bestätigte passende Lernstufe.

Modell: Eine aus Regeln oder Beispielen abgeleitete Zuordnung von Eingaben zu einer Vorhersage. Die Vorhersage muss geprüft werden.

Trainingsdaten: Fälle, aus denen ein Modell lernt. Die späteren Testfälle gehören nicht hierher.

Testdaten: Zuvor zurückgehaltene Fälle, mit denen man ein fertiges Modell möglichst unabhängig prüft.

Regression: Vorhersage einer Zahl, zum Beispiel einer Zeit in Minuten. Der Fehler lässt sich als Abstand zur tatsächlichen Zahl messen.

Klassifikation: Vorhersage einer Klasse, zum Beispiel „Übung“ oder „Vertiefung“. Eine Klasse ist keine Messzahl.

Clustering: Gruppieren ähnlicher Fälle ohne vorab festgelegtes Klassenlabel. Ähnlichkeit ersetzt noch keine fachliche Deutung.

Entscheidungsbaum: Modell aus nacheinander geprüften Bedingungen. Ein Pfad führt von einer Frage zu einer Vorhersage.

k-NN: k-nearest Neighbors: Vorhersage aus k ähnlichen gespeicherten Fällen. Die Wahl von k und die Abstände beeinflussen das Ergebnis.

Baseline: Ein einfacher Vergleichswert oder ein einfaches Vergleichsmodell. Ein aufwendigeres Modell sollte begründet besser sein.

Testgüte: Hier der Anteil richtiger Modellmeldungen an allen unbekannten Testfällen; bei anderen Fragestellungen kann eine andere Kennzahl passender sein.

Modellgüte: Beurteilung, ob ein Modell für seinen Zweck geeignet ist. Die Testgüte ist eine Kennzahl dafür; auch Fehlerarten und ihre Folgen müssen betrachtet werden.

Überanpassung: Ein Modell passt zu den Trainingsfällen sehr gut, versagt aber bei neuen Fällen. Darum getrennt testen.

MAE: Mean Absolute Error: Summe der absoluten Zahlenfehler geteilt durch die Anzahl der Fälle. Einheit wie die vorhergesagte Größe.

Verwechslungsmatrix: 2×2-Tabelle für zwei Klassen: Modellmeldung gegen tatsächlichen Fall. Sie trennt richtige und falsche positive und negative Ergebnisse.

Falsch positiv: Das Modell meldet die positive Klasse, obwohl sie tatsächlich nicht vorliegt. Die Folgen hängen vom Einsatzfall ab.

Falsch negativ: Das Modell meldet die positive Klasse nicht, obwohl sie tatsächlich vorliegt. Auch hier zählt die fachliche Folge.

Accuracy: Anteil aller richtigen Klassenmeldungen. Kann bei seltenen positiven Fällen einen wichtigen Fehler verdecken.

Precision: Anteil der richtig positiven Fälle unter allen positiven Modellmeldungen.

Recall: Anteil der erkannten positiven Fälle unter allen tatsächlich positiven Fällen.

Förderfälle erkannt: Recall, wenn „Förderbedarf“ die positive Klasse ist; gezählt werden erkannte unter allen tatsächlich vorhandenen Förderfällen.

Künstliches Neuron: Eine schematische Rechenstufe: Eingaben mit Gewichten multiplizieren, Bias addieren, Ergebnis durch eine Aktivierungsfunktion in eine Ausgabe übersetzen.

Gewicht: Zahl w an einem Eingabepfeil. Bei Eingabe $x = 1$ erhöht ein positives Gewicht die Summe, ein negatives senkt sie; bei $x = 0$ trägt es nichts bei. Im vereinfachten Papiermodell wirkt +2 stärker als +1, -2 stärker in die Gegenrichtung als -1, und 0 ignoriert dieses Merkmal. Kleine ganze Zahlen wie -2, -1, 0, +1 oder +2 sind zum Ausprobieren gut lesbar. Begründe die Wahl mit der gewünschten Reaktion auf die Eingaben. In einem trainierten Modell werden Gewichte aus Daten angepasst; für diese Skizze gibt es kein einzig richtiges Wertepaar.

Bias: Zusätzlicher Summand b in $s = w_1 \cdot x_1 + w_2 \cdot x_2 + b$. Bei $x_1 = x_2 = 0$ ist $s = b$. Gilt „Ausgabe 1 nur bei $s > 0$ “, bewirkt beispielsweise $b = +1$ schon ohne Signal eine 1, während $b = 0$ oder $b = -1$ eine 0 ergibt. Bei gleichen Eingaben und Gewichten erleichtert ein positiver Bias die Ausgabe 1, ein negativer erschwert sie. Wähle als Papiermodell zunächst einen kleinen ganzzahligen Wert passend zur gewünschten Ausgangsreaktion und prüfe die übrigen Eingaben. Im trainierten Modell wird auch b aus Daten angepasst. Hier ist Bias ein Rechenwert, keine Bezeichnung für verzerrte Daten.

Aktivierungsfunktion: Regel nach der gewichteten Summe. Im einfachen Beispiel: Ausgabe 1, falls die Summe größer als null ist, sonst 0.

Neuronales Netz: Mehrere verbundene künstliche Neuronen in Schichten. Für kleine tabellarische Fälle ist es nicht automatisch die beste Lösung.

Sprachmodell: Modell zur Erzeugung von Text aus einem Kontext. Flüssige Formulierungen sind kein Beweis für fachliche Richtigkeit.

Werkzeuge und Projektprüfung

CSV: Textdatei mit Tabellenzeilen und einem festgelegten Trennzeichen. Beim Import Spalten, Zahlen und fehlende Werte prüfen.

pandas: Python-Bibliothek zur Arbeit mit Tabellen. Der übliche Programmname ist `pd`; sie muss in der verwendeten Python-Umgebung verfügbar sein.

DataFrame: Tabellenobjekt in pandas mit Zeilen und Spalten. Beispielbefehle sind `.head()`, `.shape` und `.isna().sum()`.

Testfall: Ein definierter Eingabesatz mit erwarteter Reaktion. Bei der Prüfung werden Erwartung und beobachtete Reaktion verglichen.

Grenzfall: Ein Fall nahe einer festgelegten Grenze, etwa ein gerade noch gültiger Wert oder eine fehlende Pflichtangabe.

Menschliche Übergabe: Das System legt den Fall einer zuständigen Person vor, etwa bei Unsicherheit, Risiko oder widersprüchlichen Angaben.

Zum Inhaltsverzeichnis

Anhang: Quellen, Lizenzen und Grafiknachweise

Die schematische Neuron-Grafik zum Mensa-Parallelbeispiel wurde für dieses Lernskript selbst erstellt. Sie zeigt eine frei gewählte Rechenregel und keine reale oder trainierte Vorhersage.

Lizenz des Lernskripts: Sofern nicht anders gekennzeichnet, steht dieses Lernskript unter CC BY-NC-SA 4.0. Die Lizenz gilt nicht automatisch für verlinkte oder eingebundene Fremdmaterialien. Lizenztext: [Creative Commons](#)

Die schwarzen Outline-Icons für Arbeitsorientierung, Aufgabe, Information, Hilfe und Vertiefung wurden 2026 mit Unterstützung von OpenAI ChatGPT nach den Vorgaben der Autorin erzeugt und redaktionell geprüft. Es wurden dafür keine externen Bildvorlagen verwendet.

Dieses Lernskript wurde mit Unterstützung einer KI erstellt und anschließend redaktionell geprüft. Trotz sorgfältiger Bearbeitung können Fehler enthalten sein. Bitte melden Sie Fehler und Verbesserungsvorschläge an die Autorin.

Zentraler Kompetenzcheck

Setze eine Markierung erst, wenn du die Kompetenz sicher und anhand eines eigenen Arbeitsergebnisses nachweisen kannst.

Kapitel	Ich kann ...	Stand	Rücksprung
13	... die zentralen Arbeitsschritte zu „Daten mit pandas untersuchen und visualisieren“ erklären, anwenden und mein Ergebnis prüfen.	☐	Aufgabenblatt
14	... die zentralen Arbeitsschritte zu „Große Datenmengen sichtbar machen“ erklären, anwenden und mein Ergebnis prüfen.	☐	Aufgabenblatt
15	... die zentralen Arbeitsschritte zu „Aggregieren, ohne Wichtiges zu verstecken“ erklären, anwenden und mein Ergebnis prüfen.	☐	Aufgabenblatt
16	... die zentralen Arbeitsschritte zu „View zuerst: Dashboard des Lernagenten“ erklären, anwenden und mein Ergebnis prüfen.	☐	Aufgabenblatt
17	... die zentralen Arbeitsschritte zu „Ein reproduzierbarer ML-Workflow mit Bibliotheken“ erklären, anwenden und mein Ergebnis prüfen.	☐	Aufgabenblatt
18	... die zentralen Arbeitsschritte zu „Code lesen: von Daten zu einer Klassifikation“ erklären, anwenden und mein Ergebnis prüfen.	☐	Aufgabenblatt
19	... die zentralen Arbeitsschritte zu „Fehlerwerkstatt“ erklären, anwenden und mein Ergebnis prüfen.	☐	Aufgabenblatt
20	... die zentralen Arbeitsschritte zu „KI-	☐	Aufgabenblatt

Kapitel	Ich kann ...	Stand	Rücksprung
	Werkzeuge für BWL-Probleme auswählen“ erklären, anwenden und mein Ergebnis prüfen.		
21	... die zentralen Arbeitsschritte zu „Kriterien gewichten und bewerten“ erklären, anwenden und mein Ergebnis prüfen.	☐	Aufgabenblatt
22	... die zentralen Arbeitsschritte zu „Wirtschaftlichkeit und Verantwortung zusammendenken“ erklären, anwenden und mein Ergebnis prüfen.	☐	Aufgabenblatt

[Zum Inhaltsverzeichnis](#)